Projet Informatique en Scala

Etude de Graphes de Markov – PARTIE 2

Application aux prévisions météorologiques

I Regroupement de sommets en classes

Des sommets sont regroupés **dans une classe** s'ils communiquent tous entre eux, **c'est à dire qu'à partir d'un de ces sommets, on peut accéder à tous les sommets de cette classe (lui-même y compris).**

Ces regroupements de sommets sont nommés **composantes fortement connexes** ou **classes.**

Quelques exemples :

1) **Graphe avec 4 sommets**, sa matrice est $M=\begin{pmatrix} 0.5 & 0.5 & 0 & 0 \\ 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0.5 & 0.5 \\ 0.5 & 0 & 0 & 0.5 \end{pmatrix}$

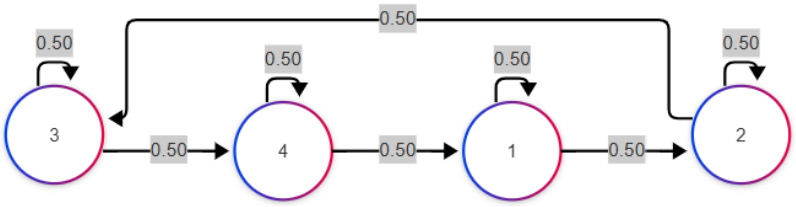

Ici, tous les sommets communiquent entre eux : partant d'un sommet, on peut accéder à tous les autres, et y revenir. On doit regrouper les 4 sommets dans une **classe** que l'on nommera **{1,2,3,4}**

2) **Graphe avec 10 sommets**, utilisé pour valider l'étape 3 de la partie 1

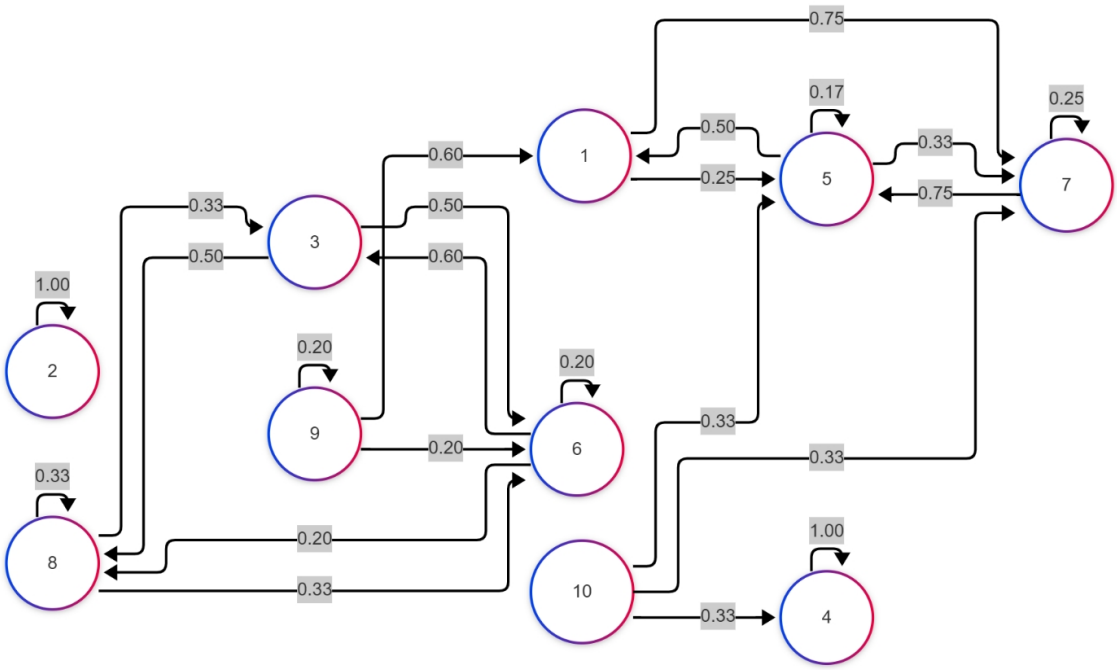

- Le sommet **2** ne communique qu'avec lui-même : il forme une **classe** à lui seul
- Le sommet **4** ne communique qu'avec lui-même : il forme une **classe** à lui seul
- Le sommet **10** forme une **classe** à lui seul également : on peut partir de **10** vers d'autres sommets, mais on ne peut pas y revenir.
- Le sommet **9** est dans le même cas : on peut en partir mais pas y revenir
- Les sommets **1**, **5** et **7** forment une classe : partant de **1**, **5** ou **7**, on peut toujours revenir à **1**,**5** ou **7**
- Les sommets **3**, **6** et **8** forment une classe : partant de **3**, **6** ou **8**, on peut toujours revenir à **3**, **6** ou **8**.

Pour ce graphe, l'ensemble des classes est donc : **{{1,5,7}, {2], {3,6,8}, {4}, {9}, {10}}**

Propriétés des classes :

- Tout sommet du graphe appartient à une et une seule classe ;
- Tout sommet du graphe doit appartenir à une classe ;
- Toute classe comporte au moins 1 sommet ;
- Un graphe comprend au moins 1 classe ;
- L'ensemble des classes d'un graphe s'appelle une **partition**.

Déterminer ces classes

Pour déterminer ces classes, de nombreux algorithmes existent, chacun avec sa difficulté de conception (est-il facile à concevoir, à comprendre ?) et sa complexité (est-il efficace ?). Les algorithmes les plus simples à comprendre et concevoir ont en général une mauvaise complexité, en $O(n^3)$ au minimum (n étant le nombre de sommets).

Nous allons utiliser un algorithme très efficace pour réaliser la partition du graphe en classes : **l'algorithme de Tarjan dont un pseudo-code est fourni.**

Entrée de l’algorithme de Tarjan :

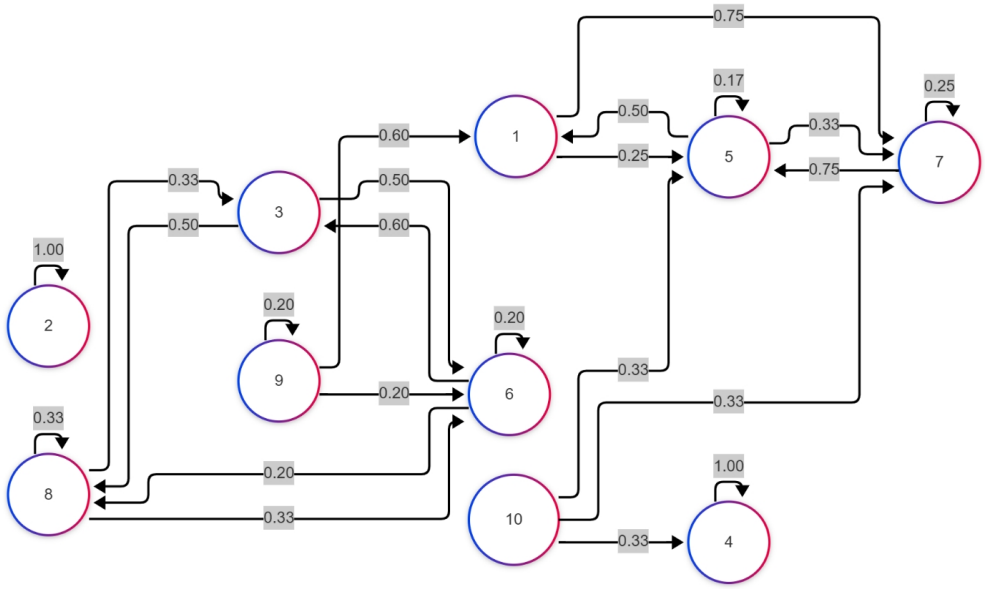

Sortie de l’algorithme de Tarjan :

```
Composante C1: {1,7,5}
Composante C2: {2}
Composante C3: {3,8,6}
Composante C4: {4}
Composante C5: {9}
Composante C6: {10}
```

L’ordre dans lequel les composantes sont affichées n’a pas d’importance

II Propriétés des graphes de Markov pour les probabilités

1) Notion de distribution

Pour le moment, nous avons associé des probabilités aux arêtes, indiquant quelle est la probabilité de passer d’un état à un autre.

Un système, à un instant donné, devrait se trouver dans un état défini en fonction d’un état de départ. Cependant, comme les transitions sont probabilistes, il n’est pas possible d’affirmer que le système se trouvera dans tel état après un certain nombre de transitions.

En revanche, on peut indiquer, pour le système, quelles sont les probabilités qu’il se trouve dans un état donné à un instant t, en fonction d’un état de départ.

Illustrations et exemples avec une graphe de Markov pour la météo

Soit le graphe de Markov suivant, illustrant (de manière totalement arbitraire), les évolutions de la météo jour après jour : chaque état représente la météo d'une journée, chaque transition indique la probabilité de passer d'un état à l'autre. Le temps discret utilisé est une journée : on calcule les évolutions d'un jour **J** à un jour **J + 1** puis de **J + 1** à **J + 2** et ainsi de suite.

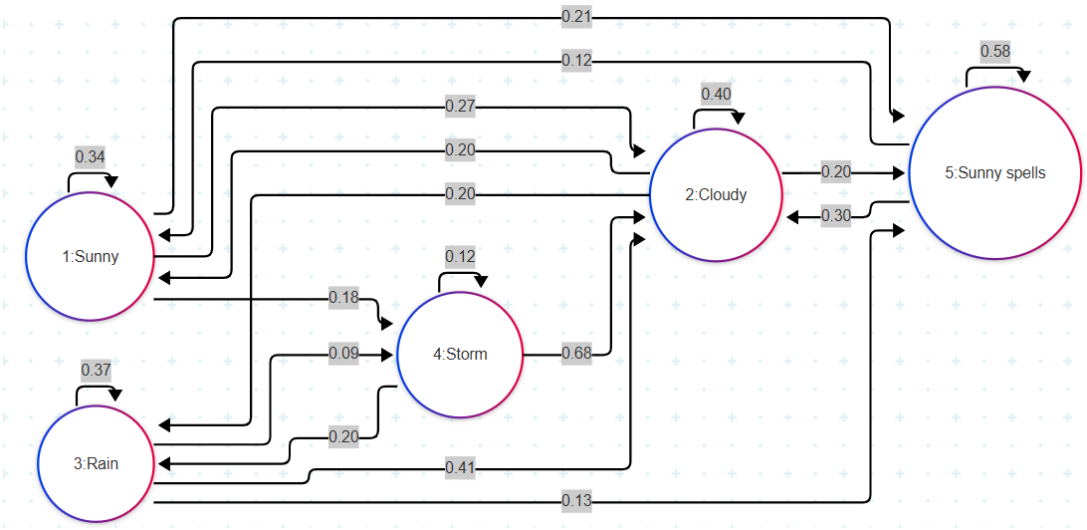

Une **distribution** représente, sur ce graphe, les probabilités d'être dans <u>un état donné à un instant donné</u>. **Une distribution** est la répartition de probabilités sur tous les états : sa somme doit être égale à 1. Il s'agit d'un **vecteur ligne**, où chaque coordonnée indique la probabilité de chaque état du graphe.

La notation consacrée pour une distribution est : Π

Exemple

Aujourd'hui il faut beau (« Sunny ») : indique que la probabilité de se trouver dans l'état 1 est égale à 1, toutes les autres valant 0.

La distribution associée est alors $\Pi = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \end{pmatrix}$

Numéro de l'état	1	2	3	4	5
Météo associée	Sunny	Cloudy	Rain	Storm	Sunny spells
Probabilité	1	0	0	0	0

2) Calcul de l'évolution en temps discret d'une distribution

En étudiant les distributions, les graphes de Markov nous permettent de répondre aux questions du type :

> **Question 1 :** « Quelle est la probabilité que le temps soit nuageux (**Cloudy**) dans 3 jours s'il fait beau (**Sunny**) aujourd'hui » ?
>
> **Question 2 :** « Quelles sont les probabilités que la météo soit dans tel état dans une semaine (7 jours) sachant qu'il pleut (**Rain**) aujourd'hui ? »
>
> **Question 3 :** « Atteint-on des probabilités indépendantes de la distribution de départ au bout d'un certain temps ? » (en termes mathématiques, existe-t-il une distribution stationnaire ?)

Principes de calcul

Le graphe de Markov étant représenté par une matrice M, et connaissant une distribution initiale Π_0, on calcule l'évolution de la distribution $\Pi_1 = \Pi_0 . M$

On peut ensuite recommencer, et calculer : $\Pi_2 = \Pi_1 . M = (\Pi_0 . M) . M = \Pi_0 . M^2$

De proche en proche, on peut donc calculer l'évolution de la distribution initiale Π_0 après *n* étapes : $\Pi_n = \Pi_0 . M^n$

Illustration avec le graphe ‘Météo’

La matrice M indique les probabilités de passage d’un état à un autre.

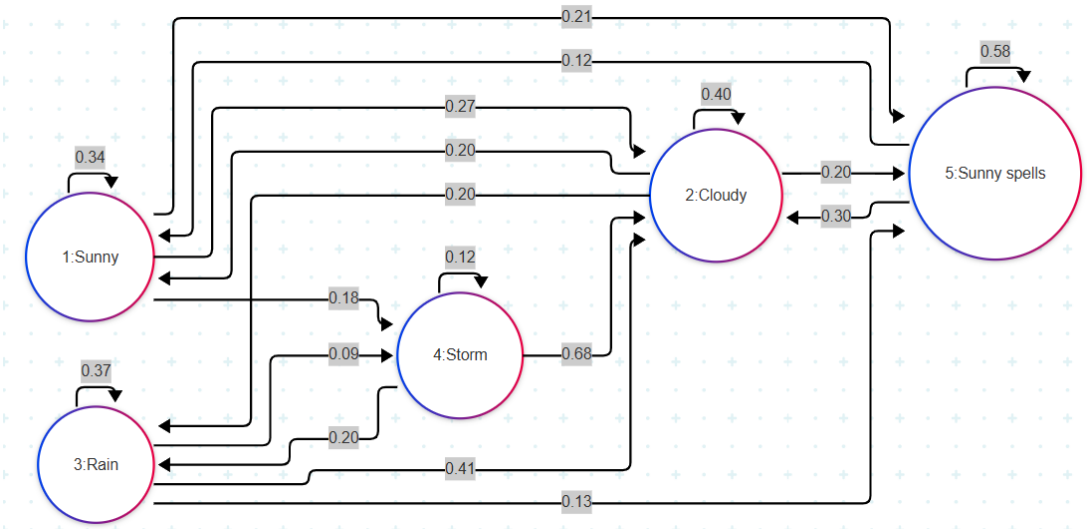

$$M = \begin{pmatrix} 0.34 & 0.27 & 0 & 0.18 & 0.21 \\ 0.20 & 0.40 & 0.20 & 0 & 0.20 \\ 0 & 0.41 & 0.37 & 0.09 & 0.13 \\ 0 & 0.68 & 0.20 & 0.12 & 0 \\ 0.12 & 0.30 & 0 & 0 & 0.58 \end{pmatrix}$$

Quels calculs devons-nous effectuer pour répondre aux questions posées ?

1) « Quelle est la probabilité que le temps soit nuageux (Cloudy) dans 3 jours s’il fait beau (Sunny) aujourd’hui » ?

2) « Quelles sont les probabilités que la météo soit dans tel état dans une semaine (7 jours) sachant qu’il pleut (Rain) aujourd’hui ? »

3) « Atteint-on des probabilités indépendantes de la distribution de départ au bout d’un certain temps ? » (en termes mathématiques, existe-t-il une distribution stationnaire ?)

<u>Pour la question 1</u> :

La distribution initiale est $\Pi_0=\begin{pmatrix}1 & 0 & 0 & 0 & 0\end{pmatrix}$

Calcul : $\Pi_3=\Pi_0.M^3$, (3 pour 'dans 3 jours') et on obtient :

$$M^3=\begin{pmatrix}0.17 & 0.37 & 0.13 & 0.05 & 0.27\\ 0.16 & 0.37 & 0.14 & 0.05 & 0.28\\ 0.14 & 0.38 & 0.18 & 0.04 & 0.25\\ 0.15 & 0.38 & 0.18 & 0.05 & 0.24\\ 0.17 & 0.34 & 0.09 & 0.04 & 0.35\end{pmatrix}$$

Puisque $\Pi_0=\begin{pmatrix}1 & 0 & 0 & 0 & 0\end{pmatrix}, \Pi_3=\begin{pmatrix}0.17 & 0.37 & 0.13 & 0.05 & 0.27\end{pmatrix}$

Numéro de l'état	1	2	3	4	5
Météo associée	Sunny	Cloudy	Rain	Storm	Sunny spells
Probabilité au bout de 3 jours	0.17	0.37	0.13	0.05	0.27

Ainsi, s'il fait beau (**Sunny**) aujourd'hui, la probabilité que le temps soit nuageux (**Cloudy**) dans 3 jours est 0.37 = 37 %.

<u>Pour la question 2</u> :

La distribution initiale est $\Pi_0=\begin{pmatrix}0 & 0 & 1 & 0 & 0\end{pmatrix}$, (il pleut, l'état est '**Rain**').

Calcul : $\Pi_7=\Pi_0.M^7$, (7 pour calculer 'dans 7 jours') et on obtient :

$$M^7=\begin{pmatrix}0.16 & 0.36 & 0.13 & 0.05 & 0.29\\ 0.16 & 0.36 & 0.13 & 0.05 & 0.29\\ 0.16 & 0.36 & 0.13 & 0.05 & 0.29\\ 0.16 & 0.36 & 0.13 & 0.05 & 0.29\\ 0.16 & 0.36 & 0.13 & 0.05 & 0.30\end{pmatrix}$$

Puisque $\Pi_0=\begin{pmatrix}0 & 0 & 1 & 0 & 0\end{pmatrix}, \Pi_7=\begin{pmatrix}0.16 & 0.36 & 0.13 & 0.05 & 0.29\end{pmatrix}$

Ainsi, s'il pleut aujourd'hui : **dans une semaine**, il y 16% de chances qu'il fasse beau, 36% de chances que le temps soit nuageux, 13% de chances qu'il pleuve, 5% de chances que le temps soit orageux, et 29% de chances qu'il y ait des éclaircies.

<u>Pour la question 3 :</u>

On constate déjà que, dans la matrice M^7, toutes les lignes sont égales (modulo les arrondis), et ainsi, quel que soit l'état de départ, le temps qu'il fait aujourd'hui, on arrive au même résultat.

Quelle que soit la météo aujourd'hui, dans une semaine, il y 16% de chances qu'il fasse beau, 36% de chances que le temps soit nuageux, 13% de chances qu'il pleuve, 5% de chances que le temps soit orageux, et 29% de chances qu'il y ait des éclaircies. Cela est aussi dû au fait que c'est une représentation très simplifiée de l'évolution de la météo.

La distribution, nommée $\Pi^{\square}=\begin{pmatrix}0.16 & 0.36 & 0.13 & 0.05 & 0.29\end{pmatrix}$ est dite **stationnaire**. Il n'y aura plus d'évolution des probabilités, et on a donc : $\Pi^{\square}.M=\Pi^{\square}$

II Implémentation

1) Calculs matriciels

Tous les éléments d'une matrice $n\,x\,n$ sont initialisés à 0.

- Ecrire une fonction qui, à partir d'une liste d'adjacence pour un graphe à n états, crée une matrice $n\,x\,n$ remplie avec les probabilités de passage entre états.
- Ecrire une fonction de multiplication de deux matrices $n\,x\,n$;
- Ecrire une fonction qui calcule 'la différence' entre deux matrices M et N : $diff(M,N)=\sum_i \sum_j |m_{ij}-n_{ij}|$ – somme des valeurs absolues des différences entre les coefficients des matrices.

Validation :

- Affichage de la matrice M associée à l'exemple météo (fichier **exemple_meteo.txt**)
- Calcul de M^3 : même résultat que celui présenté en exemple ci-dessus
- Calcul de M^7 : même résultat que celui présenté en exemple ci-dessus
- Avec les fichiers exemple : calculer M^n, pour laquelle la différence entre M^n et M^{n-1} est inférieure à $\varepsilon=0.01$. (attention, sur certains exemples, ce critère peut ne pas fonctionner : indiquez quels sont ces exemples).

2) Propriétés des graphes de Markov

Une **classe (composante fortement connexe) est dite transitoire** si on peut sortir de cette classe : il existe une flèche sortante de cette classe. Tous les états de cette classe sont dits transitoires.

Une **classe (composante fortement connexe) est dite persistante (fermée)** si on ne peut pas sortir de cette classe : il n'y a pas de flèche sortante de cette classe. Tous les états de cette classe sont dits persistants.

- Un **graphe irréductible** possède **une seule classe** et une **distribution stationnaire unique.**
- Un **graphe non irréductible** possède plusieurs classes dont :
  - Les **classes transitoires** ont une **distribution stationnaire nulle** (les probabilités sont toutes égales à 0)
  - Les **classes persistantes** ont chacune au moins une distribution stationnaire .

2.1) Ecrire une fonction d'extraction de sous-matrice correspondant à une classe du graphe.

paramètres :

- matrice d'adjacence du graphe
- la partition du graphe en composantes fortement connexes
- l'index de la composante connexe à extraire

retour :

- la sous-matrice correspondant à la composante à extraire

Dans cette sous-matrice, on ne garde que les lignes et colonnes des sommets appartenant à une composante donnée.

2.2) Ecrire une fonction retournant la **distribution stationnaire d'une classe.**

2.3) Ecrire une fonction affichant les **distributions stationnaires de toutes les classes d'un graphe.**

2.4) Tester sur les fichiers exemples fournis.